一、研究环境

A.当前指标

- **法律依据质量 (legal_basis_score, 0-1)**

  计算逻辑（基于关键词启发式，非真值对比）：

```
score = 0.0
if has_legal_basis:
    score += 0.3  # 基础分：有法律引用
    score += min(laws_mentioned * 0.2, 0.5)  # 每提到1个关键法律+0.2（最多2.5个）
    if has_specific_article:
        score += 0.2  # 有具体条款（如"第14条"）
```

  关键法律列表（9个）：

  - `['价格法', '禁止价格欺诈', '明码标价', '价格违法行为', '消费者权益', '反不正当竞争', '网络交易监督管理', '规范促销行为', '互联网平台价格行为']`

  评分示例：

  - ✅ **高分案例**（0.9分）：
    "《中华人民共和国价格法》第十四条第四项、《禁止价格欺诈行为的规定》第六条第一项"
    → 0.3（基础分）+ 0.4（2个关键法律）+ 0.2（有条款号）= 0.9
  - ⚠️ **低分案例**（0.3分）：
    "根据相关法律法规"
    → 0.3（仅基础分，无具体法律名称）

1.2 推理质量 (reasoning_score, 0-1)

计算逻辑（5个维度，累加评分）：

```python
score = 0.0
if has_reasoning:
    score += 0.2  # 基础分
    if has_facts:  # 关键词：['经查', '查实', '调查', '事实', '案情', '经营者', '商品']
        score += 0.25
    if has_legal_analysis:  # 关键词：['根据', '违反', '符合', '构成', '属于', '法规', '规定']
        score += 0.25
    if has_logic_chain:  # 关键词：['因此', '所以', '由于', '因为', '导致', '从而', '故而']
        score += 0.15
    if sentence_count >= 3:
        score += 0.15  # 结构完整性
```

满分示例（1.0分）：
"经查商家虚构原价（**事实**）。根据价格法（**法律分析**），构成违规（**法律分析**）。因此应当处罚（**逻辑链**）。"
→ 0.2 + 0.25 + 0.25 + 0.15 + 0.15 = 1.0

B. 实验环境

- **Python版本**：3.12+
- **关键依赖**：sentence-transformers, chromadb, rank_bm25
- **API平台**：讯飞星辰MaaS（Qwen、MiniMax模型）

C. 数据统计

- **处罚文书**：133份PDF，覆盖2023-2025年
- **评估数据**：159条（100违规 + 59合规）
- **法律文档**：691条（从133份PDF提取）
- **向量库规模**：691 laws + 133 cases

二、当前完成工作

2.1 数据准备

数据类型	数量	来源	用途
处罚文书PDF	133份	行政执法公开网	案例库 + 法律抽取
结构化案例	133条	PDF提取	训练数据
评估数据集	159条	人工构造 + 案例改写	系统评估
法律文档	691条	PDF抽取	向量数据库

数据集特征：

- **平台覆盖**：淘宝(29)、京东(28)、拼多多(24)、美团(21)、天猫(19)、抖音(19)、小红书(19)
- **违规类型**：虚构原价(25)、价格误导(29)、虚假折扣(25)、要素缺失(20)、其他(14)
- **场景复杂度**：简单(88)、中等(53)、复杂(18)

2.2 Baseline系统（✅ 100%完成）

实现架构：

```
用户查询 → Prompt模板 → 讯飞星辰MaaS API → 响应解析 → 结构化输出
```

技术栈：

- API接入：讯飞星辰MaaS（Qwen3.5-397B、MiniMax-M2.5、Qwen3-8B）
- Prompt工程：System + User双层提示词设计
- 结果解析：JSON提取 + 质量度量（法律依据质量、推理质量）
- 评估框架：二分类指标 + 违规类型准确率 + 性能指标

实验结果（3模型对比，159案例）：

模型	Binary Acc	Legal Basis	Reasoning	响应时间	Token消耗
Qwen3.5-397B	99.37%	91.89%	90.66%	9.85s	131K
MiniMax-M2.5	98.73%	90.57%	85.54%	8.22s	128K

模型	Binary Acc	Legal Basis	Reasoning	响应时间	Token消耗
Qwen3-8B	**99.35%**	**89.48%**	**93.00%**	**6.00s**	**111K**

关键发现：
✅ **小模型(8B)与大模型(397B)准确率相当**（差距仅0.02%）
✅ **小模型成本优势显著**（响应速度快37%，Token消耗少16%）
✅ **质量指标差距明显**（法律依据质量88-92%，存在20-30%提升空间）

2.3 RAG系统（✅ 100%完成）

实现架构：

```
Query → Embedding → 并行检索:
  ├─ 语义搜索 (Chroma向量库, Top-9)
  └─ BM25词法搜索 (691法律文档, Top-9)
     ↓
RRF融合 (k=60, 权重: BM25=1.0, Semantic=0.7) → 9-12个候选
     ↓
CrossEncoder重排序 (BGE-reranker-v2-m3) → 精排结果
     ↓
距离过滤 (threshold=0.15) + 动态Top-K → 2-3条法律 + 5个案例
     ↓
增强Prompt → LLM API → 解析输出
```

技术栈：

- 嵌入模型：`BAAI/bge-small-zh-v1.5`（中文优化，512维）
- 重排模型：`BAAI/bge-reranker-v2-m3`（跨语言多任务）
- 检索算法：BM25Okapi + 语义相似度 + RRF融合
- 向量数据库：ChromaDB（持久化存储，691法律 + 133案例）

三阶段优化实验：

阶段	技术方案	Legal Basis	Reasoning	Binary Acc
Baseline	纯LLM	89.48%	93.00%	99.35%

阶段	技术方案	Legal Basis	Reasoning	Binary Acc
Phase 1	距离过滤+动态TopK	78.34% (-11.14%)	90.00% (-3.00%)	-
Phase 2	+BM25+RRF融合	79.56% (+1.22%)	93.36% (+3.36%)	-
Phase 3	+CrossEncoder重排	**82.23%** (+2.67%)	**92.45%** (-0.91%)	**100.00%**

最终效果:

- ✅ **Binary Accuracy达到100%**（完全消除误判）
- ❌ **Legal Basis Quality低于Baseline** 82.23% vs 89.48% (-7.25%)
- ≈ **Reasoning Quality持平** 92.45% vs 93.00% (-0.55%)
- ⚠️ **成本增加**：响应时间+17.8%，Token消耗+63.5%

2.4 Agent系统（⏸️ 仅完成架构设计）

设计方案（LangGraph工作流）：

```
1. IntentAnalyzer → 解析查询意图，识别违规类型
2. HybridRetriever → 针对性检索相关法条+案例
3. Grader → 评分过滤，筛选最相关法条
4. ReasoningEngine → 多步推理生成分析
5. Reflector → 自检验证一致性
```

当前状态:

- ✅ 框架代码已完成（`src/agents/coordinator.py`）
- ❌ 各节点为占位符，未实现实际逻辑
- 预计工作量：2-3天完成MVP

三、实验结果与主要发现

3.1 核心发现

发现1：小模型性价比远超预期

数据：Qwen3-8B vs Qwen3.5-397B（参数量差50倍）

- Binary Accuracy差距：0.02%（可忽略）
- 响应速度提升：37%（6.0s vs 9.85s）
- Token成本降低：16%（111K vs 131K）

启示：在价格合规任务上，小模型+优化Prompt可以达到大模型效果，支持"小模型+RAG/Agent"的技术路线。

发现2：RAG提升准确性但降低质量

数据：RAG(Qwen3-8B) vs Baseline(Qwen3-8B)

- ✅ Binary Accuracy: 99.35% → **100.00%** (+0.65%)
- ❌ Legal Basis Quality: 89.48% → **82.23%** (-7.25%)
- ≈ Reasoning Quality: 93.00% → **92.45%** (-0.55%)

原因分析（根因诊断）：

1. **检索噪音**：检索到的法条可能包含不相关内容
2. **Prompt诱导**：模型倾向"罗列所有检索结果"而非"选择最相关的"
3. **评估局限**：启发式质量指标可能低估了RAG输出质量

证据：Violation Type Accuracy从99.35%骤降至5.73%，说明法条匹配不精确。

发现3：混合检索优于单一检索

数据：Phase 2 (BM25+Semantic) vs Phase 1 (仅Semantic)

- Legal Basis Quality: 78.34% → **79.56%** (+1.22%)
- Reasoning Quality: 90.00% → **93.36%** (+3.36%)

启示：BM25关键词匹配补充了语义检索的不足，两者融合效果更好。

发现4：CrossEncoder重排序有效

数据：Phase 3 (加重排) vs Phase 2 (无重排)

- Legal Basis Quality: 79.56% → **82.23%** (+2.67%)

方法论贡献：通过隔离测试诊断Reranker问题，确认其可用性。

3.2 实验对比总览

维度	Baseline	RAG	Agent	目标
二分类准确率	99.35%	**100.00%** ✅	未测试	99%+
法律依据质量	89.48%	82.23% ❌	未测试	95%+
推理质量	93.00%	92.45% ≈	未测试	95%+
响应时间	6.00s	7.07s (+17.8%)	未测试	<8s
Token消耗	111K	181K (+63.5%)	未测试	<150K
成本	基准	高63.5% ⚠️	未知	低于Baseline

四、遇到的问题与挑战

4.1 技术挑战

问题1：RAG降低质量的悖论 ⚠️ **核心问题**

现象：引入外部知识后，法律依据质量反而下降7.25%。

假设原因：

1. **检索召回不精确**：691法律文档中，Top-3可能包含低相关度法条
2. **Prompt设计不当**：未明确指导"选择性引用"，模型倾向"全引用"
3. **质量评估有偏**：启发式指标基于关键词匹配，可能低估RAG优势

已尝试优化：

- ✅ 混合检索（BM25+Semantic）
- ✅ CrossEncoder重排序
- ✅ 距离过滤 + 动态Top-K

仍待探索：

- ❓ 优化Prompt强调"选择最相关1-2条"
- ❓ 降低Top-K（laws_k: 3→2）减少噪音
- ❓ 提高阈值（distance: 0.15→0.12）更严格过滤
- ❓ 引入Ground Truth重新评估质量

问题2：向量检索召回率 vs 精确率权衡

挑战：Top-K增大提升召回率，但引入噪音降低精确率。

实验数据：

- Top-K=5：召回率高，但噪音大，质量78%
- Top-K=2：精确率高，但可能漏相关法条

需要探索：多轮检索（先广后精）或Query改写。

问题3：成本与效果的平衡

现状：RAG使Token消耗增加63.5%，但质量指标未提升。

ROI分析：

- Binary Accuracy提升0.65%的价值
- vs Token成本增加63.5%的代价

需要决策：RAG是否值得？还是应该优化Prompt？

4.2 数据挑战

问题4：评估指标的局限性

当前指标：基于关键词匹配的启发式评分

- Legal Basis Quality：检查法律名称、条款引用
- Reasoning Quality：检查逻辑链、结构完整性

局限性：

- 无法评估"法条相关性"（引用对法条 vs 错法条）
- 无法评估"推理逻辑严密性"（仅看结构不看内容）

改进方向：引入GPT-4评分或人工标注Ground Truth。

问题5：案例复杂度不均

分布：简单(88) > 中等(53) > 复杂(18)

影响：复杂案例评估不足，可能高估系统性能。

改进：增加复杂案例占比或分层评估。

4.3 工程挑战

问题6：跨平台API兼容性

问题：讯飞星辰MaaS API限流、超时、编码问题。

已解决：实现重试机制 + 编码规范化。

问题7：向量数据库初始化慢

问题：691法律文档首次嵌入耗时30-60秒。

已解决：使用ChromaDB持久化存储，后续加载秒级。

五、下一步工作计划

5.1 短期目标（2周内）

方案A：RAG系统优化 [**推荐优先**]

目标：将Legal Basis Quality从82.23%提升至85-88%。

具体行动：

1. **优化Prompt模板**（1天）
    - 修改System Prompt强调"只引用最相关1-2条法律"
    - 添加Few-shot示例展示"选择性引用"
2. **调整检索参数**（0.5天）
    - laws_k: 3 → 2（减少噪音）
    - cases_k: 5 → 3
    - distance_threshold: 0.15 → 0.12（更严格）
3. **增加Reranker过滤**（0.5天）
    - 设置reranker_score_threshold=0.5
    - 过滤低置信度结果
4. **全量评估**（0.5天）
    - 运行完整159案例评估
    - 生成对比报告

预期效果：Legal Basis Quality 85-88%，接近Baseline水平。

方案B：Agent系统实现 [**备选**]

目标：实现MVP，验证多步推理效果。

具体行动：

1. **实现Intent Analyzer**（1天）
    - 基于规则或小LLM识别违规类型
    - 输出：violation_type标签

2. **实现Grader**（1天）
    - 评分筛选检索结果
    - 保留Top-2法条
3. **集成测试**（0.5天）
    - 5-case MVP测试
    - 验证流程可行性
4. **全量评估**（0.5天）
    - 对比Baseline、RAG、Agent三方法

预期效果：Legal Basis Quality 88-92%（通过精准法条选择）。

5.2 中期目标（4周内）

1. **完成三方法完整对比实验**
    - Baseline、RAG、Agent全量评估
    - 生成三方法对比报告
2. **优化质量评估体系**
    - 引入GPT-4评分或人工标注
    - 建立Ground Truth评估基准
3. **撰写论文实验章节**
    - 实验设计
    - 结果分析
    - 讨论与启示

5.3 长期目标（毕业前）

1. **完成毕业论文**（8周）
    - 文献综述
    - 系统设计
    - 实验与分析
    - 结论与展望
2. **系统优化**（根据实验结果）

    - Fine-tune Reranker（如有必要）
    - Multi-hop RAG（如时间允许）
3. **代码整理与文档**
    - README完善
    - API文档
    - 部署指南

六、需要导师指导的方向

6.1 技术路线选择 ⭐ 急需决策

问题：RAG降低质量的问题如何看待?

选项:

- **A**: 继续优化RAG（Prompt + 参数调优）
- **B**: 转向Agent架构（多步推理 + Grading）
- **C**: 聚焦Baseline（优化Prompt工程，放弃RAG/Agent）

我的倾向：先尝试A（1周），若无明显提升则转B。

请导师指导:

- 在小模型已经能得到很好的结果时（准确率都在99以上），我们是否应该转向别的指标（法条引用？推理逻辑？现在的指标可行吗）
- 价格合规判断对现在的模型来说很简单，如果我们想要提高某个指标似乎不是很容易，下一步应该怎么做?

6.2 实验设计优化

问题1：评估指标是否合理?

当前启发式指标可能低估RAG质量，是否需要:

- 引入GPT-4自动评分?
- 人工标注Ground Truth（工作量大）?

- 还是继续使用启发式指标（论文中说明局限性）？

问题2：案例规模是否足够？

当前159案例，分布：

- 简单(88)、中等(53)、复杂(18)

问题：

- 虽然这个案例规模不大，但当前的实验已经说明了模型的能力足够？
- 对于复杂的案例，其实给的条件够模型肯定能判断出来，因为关于价格合规这一邻域的法条不是很复杂，价格合规仅仅是判断合规与否吗？我们还需要什么东西？做一个合规报告？

-

汇报完毕，恳请导师批评指正！